

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Departamento de Ciencias de la Computación

CC3084 Data Science Sección 11



Proyecto 1

Informe: Obtención y Limpieza de Datos

Establecimientos Educativos de Guatemala

Integrantes Grupo 3

Isabella Obando – 23074

Anthony Lou – 23410

Fabian Prado – 23427

Luis Mendoza – 19644

Fuente de datos

MINEDUC Sistema BUSCAESTABLECIMIENTO_GE

Fecha de extracción: 23 de julio de 2026

Versión del conjunto limpio: 1.0.1

Informe pipeline de limpieza de datos MINEDUC

Resumen Ejecutivo

Este informe documenta, de forma transparente y reproducible, la obtención y limpieza del conjunto de datos de establecimientos educativos de Guatemala publicado por el Ministerio de Educación (MINEDUC) a través del sistema BUSCAESTABLECIMIENTO_GE. El alcance abarca los niveles educativos comprendidos desde el nivel inicial hasta el diversificado.

A partir de una extracción cruda de 90 425 registros distribuidos en 23 archivos (22 departamentos más Ciudad Capital), se aplicó un flujo de limpieza gobernado por reglas explícitas, versionadas y auditables. El resultado es un conjunto limpio único de 90 423 registros y 18 variables, validado mediante pruebas automáticas que bloquean la exportación ante cualquier incumplimiento. Un principio rector atraviesa todo el trabajo: preservar la trazabilidad histórica del registro administrativo y evitar la eliminación o fusión automática de información, documentando cada decisión en lugar de descartar datos ante suposiciones no verificadas.

1. Introducción

La primera tarea de todo científico de datos consiste en acceder a las fuentes de información y preparar los datos para su posterior análisis. Este documento describe el proceso completo de obtención y limpieza del padrón de establecimientos educativos de Guatemala, siguiendo el orden de actividades establecido en el enunciado del Proyecto.

Todas las tablas, métricas y estadísticas presentadas se generaron mediante código Python versionado en el repositorio del proyecto, lo que garantiza que cada cifra reportada pueda reproducirse a partir de los mismos insumos. Las secciones que siguen recorren, en orden, la extracción de los datos, el diagnóstico del estado inicial, el plan de limpieza variable por variable, la ejecución de la limpieza, el registro de transformaciones, la validación, el informe de calidad, la generación del conjunto final, el libro de códigos y las condiciones de reproducibilidad.

2. Obtención de los datos y almacenamiento en CSV

Los datos se descargaron desde el portal http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/ utilizando la herramienta de automatización Playwright. Esta elección responde a que el sitio está protegido por Incapsula, lo cual impide la recuperación de contenido mediante peticiones HTTP simples. El script 03_scrape_all.py recorre los 23 valores del selector de departamento los 22 departamentos oficiales más la entrada de “Ciudad Capital” y captura la totalidad de los registros disponibles.

La consulta se ejecutó con el filtro NIVEL = TODOS con el fin de preservar intacta la extracción cruda. La restricción del dominio a los niveles del recorrido educativo hasta diversificado, así como la exclusión de categorías ajenas a ese dominio (por ejemplo, ADMINISTRATIVOS), se difiere deliberadamente a la fase de limpieza, de modo que el insumo original permanezca sin alteraciones.

Los datos crudos se almacenaron sin transformación alguna en 23 archivos CSV bajo el directorio data/crudo/ (con prefijos 00–22), uno por cada departamento o por la capital. El conjunto limpio unificado se genera posteriormente en data/limpio/establecimientos_educativos_limpio.csv.

3. Análisis del estado inicial de los datos

Antes de modificar cualquier valor se elaboró un diagnóstico exhaustivo del conjunto crudo. El diagnóstico generado por el script 04_diagnostico.py sobre la unión de los 23 archivos CSV comprende, como mínimo: el número de registros y variables, el tipo de dato de cada campo, la incidencia de valores faltantes, el conteo de valores únicos, la detección de duplicados exactos, la identificación de valores fuera de dominio, los formatos inconsistentes y los problemas potenciales de calidad. La instantánea analizada corresponde a la extracción cruda con NIVEL = TODOS.

3.1 Volumen y estructura

El conjunto crudo está compuesto por 90 425 registros y 17 variables. No existe ninguna variable numérica continua: pandas carga todas las columnas como texto, lo cual es la representación correcta, ya que campos como CODIGO, TELEFONO y DISTRITO aunque en apariencia numéricos contienen ceros a la izquierda y separadores que deben conservarse.

3.2 Tipos de dato por variable

Variable	Tipo (pandas)	Tipo lógico
CODIGO	str	Identificador / código
DISTRITO	str	Identificador / código
DEPARTAMENTO	str	Categórica
MUNICIPIO	str	Categórica
ESTABLECIMIENTO	str	Texto libre
DIRECCION	str	Texto libre
TELEFONO	str	Teléfono (texto con formato)
SUPERVISOR	str	Texto libre
DIRECTOR	str	Texto libre
NIVEL	str	Categórica
SECTOR	str	Categórica
AREA	str	Categórica
STATUS	str	Categórica
MODALIDAD	str	Categórica
JORNADA	str	Categórica
PLAN	str	Categórica
DEPARTAMENTAL	str	Categórica

3.3 Valores faltantes por variable

El análisis de completitud reveló que los faltantes se concentran en un subconjunto acotado de campos. Cabe destacar que el conteo de cadenas vacías coincide exactamente con el de valores nulos, lo que confirma que no existen valores vacíos ocultos que pandas no haya identificado al leer los archivos.

Variable	Faltantes (NaN)	% faltante
CODIGO	0	0.00 %
DISTRITO	10 031	11.09 %
DEPARTAMENTO	0	0.00 %
MUNICIPIO	0	0.00 %
ESTABLECIMIENTO	13	0.01 %
DIRECCION	829	0.92 %
TELEFONO	26 749	29.58 %
SUPERVISOR	10 039	11.10 %
DIRECTOR	26 327	29.11 %
NIVEL	0	0.00 %
SECTOR	0	0.00 %
AREA	0	0.00 %
STATUS	0	0.00 %
MODALIDAD	0	0.00 %
JORNADA	0	0.00 %
PLAN	0	0.00 %
DEPARTAMENTAL	0	0.00 %

3.4 Cardinalidad y duplicados

La variable CODIGO presenta 90 425 valores únicos sobre 90 425 registros, lo que la confirma como llave primaria del conjunto. No se detectaron duplicados exactos (filas idénticas en todas sus columnas) ni colisiones de CODIGO entre departamentos. Las variables categóricas presentan cardinalidades coherentes con su dominio esperado: DEPARTAMENTO con 23 valores (por la partición Ciudad Capital / Guatemala), NIVEL con 9, SECTOR con 4 y AREA con 3.

3.5 Valores fuera de dominio

El cotejo contra los dominios definidos por el formulario del sitio identificó dos anomalías puntuales: la variable NIVEL contiene 2 registros con la categoría ADMINISTRATIVOS, ajena al recorrido educativo, y la variable AREA presenta 5 registros con el valor SIN ESPECIFICAR, que semánticamente corresponde a un dato faltante y no a una tercera categoría geográfica. Las variables SECTOR y MODALIDAD no presentaron valores fuera de dominio.

3.6 Inconsistencias de formato

El diagnóstico de formato arrojó los siguientes hallazgos principales:

- La variable CODIGO cumple en su totalidad el patrón NN-NN-NNNN-NN: no se registró ningún valor fuera de patrón.
- La variable TELEFONO presenta 699 valores con separadores o texto (por ejemplo, «CEL. ...»), 134 valores compuestos solo por dígitos pero con una longitud distinta de 8 —el estándar guatemalteco— y 133 valores con el literal «S/D».
- Se detectaron espacios dobles internos en varios campos de texto libre: ESTABLECIMIENTO (4 249), DIRECCION (1 987), SUPERVISOR (308) y DIRECTOR (9 336).
- La variable DISTRITO exhibe dos formatos coexistentes —NN-NN-NNNN (53 093 filas) y NN-NNN (27 230 filas)— además de 71 filas con un formato incompleto del tipo NN-.
- La variable DIRECTOR contiene 2 102 valores que son placeholders textuales de «sin dato» (-, S/D, SIN DATO, entre otros), lo que infla artificialmente el conteo de valores únicos y enmascara el verdadero porcentaje de faltantes.

3.7 Problemas potenciales de calidad

Ciudad Capital frente a Guatemala. El menú desplegable de origen distingue «Ciudad Capital» (value = 00) de «Guatemala» (value = 01); sin embargo, administrativamente la capital es el municipio de Guatemala dentro del departamento de Guatemala. Al no existir solapamiento de CODIGO entre ambos grupos, se trata de una partición del sitio web y no de una duplicación de datos.

Re-registro administrativo. Un total de 4 208 filas comparten el conjunto ESTABLECIMIENTO + DIRECCION + MUNICIPIO + NIVEL + JORNADA + SECTOR con un CODIGO distinto y, en la mayoría de los casos, un STATUS diferente (una fila ABIERTA y otra CERRADA o histórica). Esto sugiere el re-registro administrativo de un mismo establecimiento bajo un código nuevo a lo largo del tiempo, y no un duplicado exacto.

4. Plan de limpieza

Antes de aplicar cualquier transformación se definió un plan variable por variable en el que se especifican, para cada campo, los problemas detectados, la regla de corrección adoptada con su respectiva justificación y los riesgos asociados. El plan se apoya en el diagnóstico de la instantánea cruda de 90 425 registros por 17 variables extraída el 23 de julio de 2026.

Regla transversal. En los campos de texto libre (ESTABLECIMIENTO, DIRECCION, SUPERVISOR y DIRECTOR) no se modifica la ortografía, las tildes, la letra «ñ» ni el uso de mayúsculas y minúsculas del texto original. Este criterio conservador permite citar los nombres tal como aparecen en la fuente; únicamente se corrigen problemas puramente de formato, como los espacios dobles o los valores que en realidad significan «sin dato» pero fueron capturados como texto.

4.1 Identificadores y códigos

CODIGO. No presenta problemas: cumple en su totalidad el patrón NN-NN-NNNN-NN y es llave única. Se mantiene sin cambios como texto para preservar ceros a la izquierda y guiones y se emplea como llave primaria del conjunto limpio.

DISTRITO. Presenta un 11.09 % de faltantes y dos formatos coexistentes. No se fuerza un formato único, dado que no hay certeza de que ambos esquemas signifiquen lo mismo (posiblemente reflejan una reestructuración administrativa en distintos años); ambos se documentan como válidos en el libro de códigos. Los 71 casos con formato incompleto NN- se convierten a valor faltante explícito por carecer de información utilizable.

4.2 Geografía administrativa

DEPARTAMENTO. Guatemala cuenta oficialmente con 22 departamentos, no 23. Puesto que Ciudad Capital es el municipio de Guatemala y no existe solapamiento de CODIGO entre ambos grupos, para el conjunto limpio se unifica «Ciudad Capital» dentro de DEPARTAMENTO = GUATEMALA. La decisión se documenta de forma explícita para evitar que un conteo posterior contabilice erróneamente 23 departamentos.

MUNICIPIO y variable derivada ZONA. Bajo el grupo «Ciudad Capital», esta columna contiene categorías del tipo «ZONA n» en lugar de un municipio real. Al aplicar la unificación, dichas filas se reasignan a MUNICIPIO = GUATEMALA, pero la información de zona no se descarta: se extrae del valor original y se preserva en una nueva variable ZONA (poblada únicamente para las filas que antes correspondían a la capital). Esta extracción captura el 100 % de los casos.

4.3 Texto libre y contacto

ESTABLECIMIENTO, DIRECCION y SUPERVISOR. La única transformación consiste en recortar y colapsar los espacios internos múltiples, respetando íntegramente la ortografía, las tildes y la capitalización originales. Los registros sin nombre se dejan como faltante explícito, sin inventar valores. En el caso de SUPERVISOR, se reconoce que la columna mezcla legítimamente personas y entidades (por ejemplo, «PROYECTO FUNDAZUCAR»), por lo que no se «corrigen» esos valores.

DIRECTOR. Además del 29.11 % de faltantes ya identificados como nulos, 2 102 filas emplean placeholders textuales para expresar «sin dato». Todos ellos se homologan a valor faltante explícito, lo que revela el

porcentaje real de ausencia de información (aproximadamente 31.43 %) y depura el conteo de valores únicos. Sobre los nombres reales solo se colapsan espacios dobles.

TELEFONO. Los valores «S/D» y equivalentes se convierten a faltante; de los registros con múltiples números se conserva el primer número válido de ocho dígitos; los valores compuestos solo por dígitos con longitud distinta de ocho se convierten a faltante, sin completar ni truncar cifras ambiguas. El resultado es una columna uniforme (ocho dígitos o valor faltante), utilizable directamente para validación o contacto.

4.4 Variables categóricas

NIVEL. Se conservan las ocho categorías del recorrido educativo desde inicial hasta diversificado y se excluyen los 2 registros ADMINISTRATIVOS por quedar fuera del alcance del proyecto.

AREA. El valor SIN ESPECIFICAR (5 filas) se convierte a faltante explícito, ya que semánticamente representa ausencia de dato y no una categoría geográfica adicional.

SECTOR, MODALIDAD, STATUS, JORNADA, PLAN y DEPARTAMENTAL. Se conservan sin cambios de contenido y se documentan en el libro de códigos. Se advierte de forma expresa que cualquier conteo de «establecimientos activos» debe filtrar por STATUS = ABIERTA, y que la categoría SIN JORNADA es válida (coherente con planes a distancia o virtuales) y no debe interpretarse como faltante.

4.5 Duplicados parciales y unión final

No existen duplicados exactos. No obstante, 4 208 filas comparten un conjunto de atributos clave con un CODIGO distinto y, casi siempre, un STATUS diferente, lo que apunta a un re-registro administrativo del mismo establecimiento físico. La política adoptada es no eliminar estas filas: cada CODIGO constituye un registro administrativo legítimo con su propio historial.

Para la revisión difusa se comparan los campos ESTABLECIMIENTO, DIRECCION y TELEFONO con un umbral de similitud de 0.90, exigiendo la coincidencia de al menos dos de los tres criterios; el teléfono por sí solo nunca es suficiente y se descarta como bloque cuando aparece en más de 20 registros. Los pares que cumplen la regla se consolidan por componentes relacionados en grupos, y a cada grupo se le asigna la decisión CONSERVAR_TODOS según el primer patrón aplicable: red de establecimientos con mismo nombre y distinta dirección, re-registro administrativo, teléfono institucional compartido o candidato por similitud conservado. Ningún registro se elimina ni fusiona de forma automática.

5. Ejecución de la limpieza

La limpieza se implementó de manera reproducible en el módulo `limpieza.py` y se ejecutó desde el cuaderno `05_limpieza.ipynb`. Las operaciones cubren los aspectos exigidos por el enunciado siempre que resultan aplicables:

- Valores faltantes, cadenas vacías y placeholders textuales se homogenizan a valor faltante cuando representan una ausencia real de información.
- Todas las variables se conservan como texto, dado que CODIGO, DISTRITO y TELEFONO requieren ceros a la izquierda o formatos no numéricos.
- En los campos libres se recortan y colapsan los espacios, sin alterar la ortografía, las tildes ni la capitalización original.
- Se unifica Ciudad Capital en DEPARTAMENTO = GUATEMALA y MUNICIPIO = GUATEMALA, derivando la variable ZONA para no perder la ubicación capitalina.
- El teléfono se estandariza al primer número de ocho dígitos o a faltante, y CODIGO se valida contra el patrón NN-NN-NNNN-NN.
- Los departamentos y municipios se contrastan contra el catálogo SEGEPLAN 2026 (con los alias documentados de MINEDUC) y se excluyen los niveles fuera del recorrido hasta diversificado.
- Se detectan duplicados exactos y parciales; estos últimos mediante similitud de cadenas. Ningún registro se elimina de forma automática y cada decisión queda documentada por patrón.

5.1 Decisión sobre duplicados parciales

Mediante similitud de cadenas (SequenceMatcher, umbral 0.90) sobre nombre, dirección y teléfono, exigiendo al menos dos criterios coincidentes, se identificaron 14 359 grupos candidatos a duplicado parcial. La política adoptada fue conservar todos los registros, sin eliminación ni fusión automática. La distribución de decisiones fue CONSERVAR_TODOS = 14 359, con la siguiente distribución de patrones: red con mismo nombre y distinta dirección = 3 298; re-registro administrativo = 11 061. El detalle caso por caso se conserva en `reports/duplicados_parciales.csv`. Los duplicados exactos en el conjunto limpio son cero.

6. Registro de transformaciones

Toda modificación quedó documentada en la siguiente tabla de trazabilidad, que consigna para cada regla la variable afectada, el problema detectado, la transformación aplicada, el número de registros afectados y su justificación. La tabla se genera automáticamente desde el cuaderno de limpieza.

Variable	Problema	Transformación	Reg.	Justificación
NIVEL	Nivel fuera del recorrido hasta diversificado	Excluir el registro del conjunto limpio	2	Mantener solo niveles de inicial a diversificado
DISTRITO	Código incompleto NN-	Convertir a valor faltante	71	No contiene un identificador utilizable
DEPARTAMENTO / MUNICIPIO / ZONA	Ciudad Capital usa zonas como municipios	Unificar en Guatemala y derivar la zona	3 908	Alinear con los 22 departamentos sin perder la zona

Variable	Problema	Transformación	Reg.	Justificación
ESTABLECIMIENTO	Espacios iniciales, finales o múltiples	Recortar y colapsar espacios	4 249	Uniformar formato sin alterar ortografía
DIRECCION	Espacios iniciales, finales o múltiples	Recortar y colapsar espacios	1 987	Uniformar formato sin alterar ortografía
SUPERVISOR	Espacios iniciales, finales o múltiples	Recortar y colapsar espacios	360	Uniformar formato sin alterar ortografía
DIRECTOR	Espacios iniciales, finales o múltiples	Recortar y colapsar espacios	9 336	Uniformar formato sin alterar ortografía
DIRECTOR	Placeholder textual de dato faltante	Convertir a valor faltante	2 100	Representar faltantes de forma consistente
TELEFONO	Formato distinto de ocho dígitos	Conservar el primer número de 8 dígitos o convertir a faltante	834	No completar ni truncar números ambiguos
AREA	Categoría SIN ESPECIFICAR	Convertir a valor faltante	5	Es ausencia de información, no un área
DUPLICADOS PARCIALES	Grupos candidatos por similitud	Documentar CONSERVAR_TODOS por patrón (0 eliminados)	14 359	Preservar el historial administrativo completo

7. Validación del conjunto limpio

Al concluir la limpieza se ejecutaron pruebas automáticas de calidad que bloquean la exportación si alguna de ellas falla. Estas verificaciones comprueban la ausencia de duplicados exactos, la inexistencia de espacios iniciales o finales en los textos, la uniformidad del formato telefónico, la pertenencia de departamentos y municipios al catálogo oficial, la corrección de los tipos, la ausencia de categorías duplicadas por escritura y la eliminación de los valores inválidos diagnosticados. La totalidad de las pruebas se superó con éxito.

Prueba	Resultado	Detalle
Sin duplicados exactos	OK	0
Sin espacios iniciales o finales	OK	0
Teléfonos con formato uniforme	OK	0
Departamentos dentro del catálogo	OK	[]
Municipios consistentes con la fuente	OK	[]
Variables con el tipo esperado	OK	[]
Sin categorías duplicadas por escritura	OK	{}
Sin valores inválidos diagnosticados	OK	CODIGO, DISTRITO, DIRECTOR, AREA = 0
Zona consistente con Guatemala	OK	0
Niveles dentro del recorrido permitido	OK	8 categorías válidas

8. Informe de calidad de los datos

La siguiente tabla compara el estado del conjunto antes y después de la limpieza, según las métricas exigidas por el enunciado.

Métrica	Antes	Después
Registros	90 425	90 423
Variables	17	18
Valores faltantes	73 988 (4.81 %)	163 131 (10.02 %)
Variables con faltantes	6	8
Duplicados exactos	0	0
Posibles duplicados	14 366	14 359
Variables con formato inconsistente	7	0
Variables con tipo incorrecto	0	0
Categorías inconsistentes	0	0
Errores corregidos	0	37 211

8.1 Interpretación de los cambios

El número de registros descendió de 90 425 a 90 423 debido a la exclusión de los 2 registros con NIVEL fuera del recorrido educativo. El número de variables aumentó de 17 a 18 por la incorporación de la variable derivada ZONA. El incremento aparente de valores faltantes de 4.81 % a 10.02 % no representa una pérdida de calidad, sino todo lo contrario: refleja que los placeholders textuales que antes enmascaraban ausencias de información (principalmente en DIRECTOR) ahora se contabilizan correctamente como faltantes explícitos. Las siete variables con formato inconsistente se redujeron a cero, y el conteo de errores corregidos corresponde a la suma de registros afectados por cada regla.

9. Generación del conjunto limpio

Se generó un único conjunto de datos con la información de todos los departamentos en `data/limpio/establecimientos_educativos_limpio.csv`. El archivo cumple con una estructura consistente de 18 columnas incluida ZONA, tipos de dato correctos (texto), nombres de variables descriptivos y documentados, formato uniforme validado por las pruebas y ausencia de errores detectados en la fase de validación. Los metadatos del conjunto son: fecha de extracción 23 de julio de 2026, versión 1.0.1 y fuente MINEDUC BUSCAESTABLECIMIENTO_GE.

10. Libro de códigos

Para cada variable se documentan su descripción, tipo de dato, dominio permitido, tratamiento aplicado, carácter derivado y número de valores faltantes en el conjunto limpio. La versión completa se encuentra también en [reports/libro_codigos.md](#) y [reports/libro_codigos.pdf](#).

Variable	Descripción	Dominio	Deriv.	Faltan.
CODIGO	Identificador único del registro educativo	Patrón NN-NN-NNNN-NN	No	0
DISTRITO	Código administrativo de distrito	NN-NNN o NN-NN-NNNN; admite faltante	No	10 102
DEPARTAMENTO	Departamento de Guatemala	22 departamentos oficiales	No	0
MUNICIPIO	Municipio del establecimiento	Catálogo SEGEPLAN 2026	No	0
ZONA	Zona de Ciudad de Guatemala cuando aplica	Número de zona o faltante	Sí	86 515
ESTABLECIMIENTO	Nombre del establecimiento educativo	Texto o faltante	No	13
DIRECCION	Dirección reportada del establecimiento	Texto o faltante	No	829
TELEFONO	Teléfono principal reportado	Ocho dígitos o faltante	No	27 201
SUPERVISOR	Persona o entidad supervisora	Texto o faltante	No	10 039
DIRECTOR	Nombre de la persona directora	Texto o faltante	No	28 427
NIVEL	Nivel escolar del establecimiento	Inicial a diversificado	No	0
SECTOR	Sector administrativo	Oficial, Privado, Municipal, Cooperativa	No	0
AREA	Área geográfica	Urbana, Rural o faltante	No	5
STATUS	Estado administrativo del registro	Categorías de la fuente	No	0
MODALIDAD	Modalidad lingüística	Monolingüe o Bilingüe	No	0
JORNADA	Jornada educativa	Categorías de la fuente	No	0
PLAN	Plan de estudios o asistencia	13 categorías de la fuente	No	0
DEPARTAMENTAL	Oficina departamental responsable	26 categorías de la fuente	No	0

11. Reproducibilidad

El proceso completo es reproducible mediante scripts numerados y un entorno declarado en requirements.txt. Los archivos CSV crudos no se modifican durante el diagnóstico ni la limpieza; las reglas residen en limpieza.py y los reportes intermedios en Markdown permiten auditar cada etapa. El orden de ejecución recomendado es el siguiente:

1. `python 03_scrape_all.py`
2. `python 04_diagnostico.py`
3. `jupyter nbconvert --to notebook --execute --inplace 05_limpieza.ipynb`
4. `python 06_libro_codigos.py --fecha-extraccion 2026-07-23 --version 1.0.1`

Todo el proceso e instrucciones necesarias para reproducir la limpieza de datos se encuentran en el siguiente repositorio de GitHub: [anthonylouschwank/Proyecto1-DS](https://github.com/anthonylouschwank/Proyecto1-DS)